

Segmentación de imágenes por métodos de clustering

Rubén Darío Bohórquez Cortázar
Universidad de los Andes
Bogota, Colombia

rd.bohorquez10@uniandes.edu.co

Javier Felipe Cifuentes
Universidad de los Andes
Bogota, Colombia

jf.cifuentes10@uniandes.edu.co

Abstract

En este laboratorio se desarrolló una función en Matlab, la cual permite realizar la segmentación de una imagen a través de la selección del método de segmentación, el espacio de representación y el número de clusters; se debe resaltar que los métodos estudiados fueron implementados para realizar una segmentación basada en el color y la disposición espacial. Para el desarrollo de este código, se evaluaron los siguientes métodos de segmentación por clustering, k-means, mezcla de gaussianas, segmentación jerárquica y watersheds. De igual forma, se evaluó la eficiencia de cada uno de estos métodos en los siguientes espacio de representación rgb, lab, hsv, rgb+xy, lab+xy y hsv+xy. Por otro lado, se desarrolló una metodología de evaluación que permitiera comparar estos métodos de segmentación y de esta forma definir cuál era el mejor método y en qué espacio de representación funcionaba mejor. Partiendo de esto, Se logró realizar la segmentación de las imágenes empleando las distintas combinaciones de métodos de segmentación, espacios de representación y numero de clúster. Para cada combinación se calculó el índice de Jaccard promedio, lo cual permitió realizar una comparación objetiva del desempeño de cada uno de los métodos analizados en el estudio. Con esto se determinó que la combinación que presentó los mejores resultados atinentes al mayor índice de Jaccard promedio era la correspondiente al algoritmo de mezcla de gaussianas en el espacio de representación RGB y con un total de 3 clusters. Con los resultados obtenidos, se pudo concluir que adicionar la información espacial no representó una ventaja significativa para la segmentación de imágenes basado en el color. De igual forma, se puede afirmar que el color no es un parámetro suficientemente significativo para solucionar el problema de la segmentación de imágenes. Adicionalmente, parámetros como el espacio de representación y el número de cluster juegan un papel fundamental en la aplicación de algoritmos de segmentación basados en clustering.

1. Introducción

La segmentación es la división de una imagen en regiones, las cuales en esencia corresponden a los componentes u objetos presentes en la misma.[1] El objetivo principal de la segmentación es separar las partes o componentes de interés del resto de la imagen. Otra definición ampliamente utilizada, considera la segmentación como una clasificación de píxeles, en la cual se indican las clases a las cuales corresponden los distintos píxeles. Además, principalmente se consideran esas clases o categorías como los objetos o componentes presentes en la imagen.[1] Existen diversos parámetros o atributos empleados para realizar la segmentación, entre los más utilizados se encuentran: color (en imágenes de color), textura, forma, luminancia (imágenes en niveles de gris), entre otros. El problema de segmentación ha sido ampliamente estudiado en el área de análisis de imágenes, debido a esto, se han desarrollado múltiples algoritmos para la solución de este problema.[1] Por consiguiente, el objetivo de este estudio es analizar el comportamiento de diversos métodos de segmentación de imágenes por clustering basado en color y disposición espacial, y evaluar su desempeño en una base de datos. Para esto, se va a desarrollar una función en Matlab, la cual va a tener como parámetros, el espacio de color, el método de segmentación, el número de clusters y la imagen.

2. Materiales y métodos

2.1. Espacios de representación

Lo primero que se realizó fue transformar la imagen a su respectivo espacio de representación. Para este fin el algoritmo divide los espacios posibles en dos casos, con o sin información espacial. Cuando el espacio no tiene información espacial, se procede a cambiar la imagen al espacio de color escogido para luego ser normalizado. En el caso de ser un espacio con información espacial, se lleva a cabo el mismo procedimiento, sin embargo, se añaden dos canales a la imagen normalizada. Uno de estos canales tiene información de la variable y, mientras que el otro tiene información de x. Esto se logró con la función meshgrid de Mat-

lab, para generar las dos matrices a añadir. Estas también fueron normalizadas. Finalmente se transforma esta matriz de 3 dimensiones en una de dos, en la cual, cada columna representa un canal de color o espacio y cada fila un pixel.

2.2. K means

Si el método escogido fue K means, se procede a hacer un proceso de clustering utilizando la función kmeans de Matlab. Esta recibe como parámetros, los datos, en forma de matriz bidimensional y el número de clúster. Esta devuelve un mapa y un vector de centroides. Posteriormente se generó un reshape sobre el mapa de manera que se muestre como imagen. Esta es la imagen resultado.

2.3. Mezcla de gaussianas

Para el proceso de mezcla de gaussianas, se sigue un procedimiento similar al de k means. Se utiliza la función fitgmdist para ajustar funciones gaussianas a los datos. A partir de este resultado, se utiliza la función cluster. Para asignar cada uno de los puntos a una función y así, darles un valor. Posteriormente a este nuevo vector se le altera la forma con un reshape, para obtener la imagen segmentada.

2.4. Segmentación jerárquica

Este método de segmentación comienza con la función pdist. Esta genera un vector de distancias, entre cada uno de los pixeles, con el resto de los mismos. Luego, se utiliza la función linkage, la cual agrupa la pareja e pixeles con distancia mínima, para generar un cluster. Posteriormente se realiza el mismo procedimiento, pero tomando este nuevo cluster como elemento, en lugar de los dos pixeles que lo componen. La función se detiene cuando toda la imagen pertenece a un solo cluster. Finalmente se utiliza la función cluster, la cual toma esta matriz de linkage, y encuentra el punto en el cual se tiene el número de clúster deseados. Luego se le asigna un valor a cada pixel para luego generar la imagen resultado.

2.5. Watershed

Para utilizar esta función es necesario establecer mínimos locales sobre la imagen, para evitar la sobre segmentación. Para hallar estos mínimos se genera el gradiente de la imagen. A partir de esta imagen, se da una binarización. Luego se encuentra el complemento de la imagen, y se erosionan los componentes conexos, hasta tener el número de cluster deseados. Una vez que esto se logra, se establecen como mínimos de la imagen y se aplica la función watershed de Matlab. Esto debe realizarse por canal y no por toda la imagen.

3. Resultados

Se logró segmentar cada imagen en cada uno de los espacios de representación variando el número de clusters. No

obstante, no se realizó la segmentación por el método de Watersheds en los espacios de representación que tenían en cuenta la disposición espacial (+xy). Se puede ver como ejemplo la segmentación de la imagen de la iglesia, mostrada en la figura 2. Se muestran diferentes tipos de segmentación para 3 clusters con diferentes métodos en las figuras 4, 6 y 5. Se muestra otro ejemplo en la figura 7. Esta imagen se segmentó en 4 clusters con diferentes métodos, mostrados en las figuras 9, 10 y 11. Se calculó el índice de Jaccard para cada combinación de método de segmentación, espacio de representación y número de clúster, para cada una de las imágenes con respecto a una de las anotaciones presentes en la base de datos, la cual fue seleccionada de manera cualitativa por el grupo de investigación. Se muestran ejemplos de las anotaciones escogidas en las figuras 3 y 8, para la imagen de la iglesia y del paisaje, respectivamente.

Ahora bien, para poder comparar los métodos estudiados, se procedió a calcular un índice de Jaccard promedio para cada una de las combinaciones de espacio de representación y método de segmentación. Los resultados del índice promedio se exponen en la siguiente tabla.

Kmeans	Rgb	0.34
Kmeans	Lab	0.3872
kmeans	hsv	0.40
kmeans	rgb+xy	0.22
kmeans	lab+xy	0.31
kmeans	hsv+xy	0.42
Gmm	Rgb	0.51
Gmm	Lab	0.44
Gmm	hsv	0.40
Gmm	rgb+xy	0.45
Gmm	lab+xy	0.429
Gmm	hsv+xy	0.429
Jerarquica	Rgb	0.4275
Jerarquica	Lab	0.4275
Jerarquica	hsv	0.4558
Jerarquica	rgb+xy	0.4274
Jerarquica	lab+xy	0.4274
Jerarquica	hsv+xy	0.4578
watersheds	Rgb	0.34
watersheds	Lab	0.34
watersheds	hsv	0.41

Figure 1. Tabla de resultados en la cual se muestra el índice de Jaccard promedio para cada método con su respectivo espacio de representación

4. Análisis de resultados

El número de cluster es un parámetro muy importante ya que este determina el número de objetos que serán segmentados en la imagen. En el caso ideal, se espera

introducir como parámetro el número de cluster que corresponde al número total de objetos a segmentar en la imagen. No obstante, para este laboratorio en específico, el número de clusters estaba asociado a un problema bastante peculiar. En esencia, se espera que al aumentar el número de cluster y hacer que esta tienda al número de regiones segmentadas en las anotaciones, la métrica de evaluación debe exponer mejores resultados. No obstante, con los resultados obtenidos se identificó que al aumentar el número de clusters disminuía la eficiencia de los métodos de segmentación, esto se puede explicar debido a que, para la comparación de múltiples regiones, la métrica de evaluación utilizada no es la mejor, además, al aumentar el número de clusters la segmentación basada en el color no se aproxima de manera certera a las regiones anotadas. Al utilizar el parámetro de color como principal base para la segmentación, se obtiene como resultado que todos los píxeles con color similar serán vinculados al mismo cluster, incluso, si estos pertenecen a objetos diferentes; esto implica que, aunque se utilice una mayor cantidad de cluster como parámetro, no va a mejorar considerablemente la segmentación basada en color, debido a que los píxeles similares seguirán siendo agrupados en un mismo cluster. La estrategia que se evaluó para corregir este problema, fue incluir la información espacial en los espacios de representación, no obstante, los resultados no fueron los esperados, debido a que los objetos diferentes que se encontraban cercanos en la imagen pero que poseían colores similares, con la información espacial fueron agrupados en el mismo cluster, lo cual generó en algunos casos, una disminución en el índice de Jaccard.

Ahora bien, se debe resaltar que el análisis realizado anteriormente está ligado estrechamente con el tipo de imagen que se esté procesando, debido a que en las imágenes donde los distintos objetos presentaban colores muy distintos, la segmentación basada en el color funcionaba perfectamente. No obstante, en las imágenes en las cuales los objetos presentaban colores muy similares, la segmentación por color no era suficiente para realizar la correcta subdivisión de las regiones, además, la información espacial adicional no presentaba una gran mejora para la solución de este problema. De igual forma, se debe resaltar que al aumentar el número de cluster, mejoraba en cierta medida la separación de los objetos cuyos colores eran similares, pero no iguales, no obstante, esto también generaba sobre segmentación en algunos objetos para los cuales el objetivo principal era obtenerlos como una sola región. Todo esto expone claramente que la segmentación basada solo en el color y en la disposición espacial, no es suficiente para solucionar el problema de la segmentación de imágenes.

Por otro lado, debido a que la selección de las anotaciones se realizó de forma cualitativa y subjetiva, se puede

afirmar que esta selección presenta una fuente de error para la evaluación de los distintos métodos. Esto debido a que, si la anotación seleccionada no es la mejor para evaluar con respecto al índice de Jaccard, los resultados del mismo se verán afectados negativamente, lo que puede verse reflejado en la obtención de resultados no confiables, sobre los cuales no se puede dar un veredicto certero acerca de cuál de los métodos de segmentación utilizados es el mejor.

Ahora bien, el espacio de representación en el cual se implementaban los métodos jugó un papel muy importante a la hora de realizar el análisis de los resultados obtenidos. Esto debido a que se evidenció que para ciertos métodos de segmentación había unos espacios de representación que mejoraban los resultados obtenidos significativamente. Tiene especial relevancia el usar espacios de color diferentes a RGB, dado que RGB es un espacio no uniforme de color. A diferencia de espacio de color como Lab, los cuales presentan uniformidad a lo largo de todos los canales. Un espacio de color uniforme permite presentar las distancias entre puntos en el espacio de manera lineal, lo cual da más consistencia a un proceso de clustering, en el cual se determinan distancias para hallar similitud entre píxeles. Adicionalmente, si se quiere dar robustez a los algoritmos de segmentación, se deben considerar nuevos parámetros distintos al color, tales como la textura y la forma, para estos nuevos parámetros, es de gran importancia utilizar un espacio de representación uniforme el cual permite obtener los mejores resultados, para estos casos, el espacio de representación Lab es el más utilizado. Por otro lado, se debe resaltar que se debe escoger cuidadosamente el espacio de representación a utilizar, debido a que la respuesta de los métodos de segmentación implementados no es consistente para todos los espacios. Esto implica que para cada método existe un espacio de representación en el cual su eficiencia es óptima. Adicionalmente esto explica también la razón por la cual es intuitivo el uso de espacios distintos a RGB, debido a que algunos métodos presentan un mejor desempeño en otros espacios de representación diferentes. Por ejemplo, en los resultados obtenidos se pudo evidenciar que el método de mezcla de gaussianas tuvo un mejor desempeño al implementarlo en el espacio de representación RGB, no obstante, el método de segmentación jerárquica presentó mejores resultados en hsv que en RGB.

Como se puede evidenciar en la tabla, el mejor método con el índice de jaccard promedio más alto resulta ser el método de mezcla de gaussianas. Este es un método de clustering que presenta algunas ventajas sobre los métodos de kmeans, así como watersheds y jerárquico. Para empezar, el método de kmeans es el método más simple de clustering. Este tiende a ser muy sensible con respecto a la inicialización de los centroides, adicionalmente muestra una tendencia a agrupar los datos en "formas circulares", como en agrupamientos esféricos o circulares de datos. Por otro lado

la función de mezcla de gaussianas, aproxima los datos a funciones, mostrando patrones más precisos para los datos. Por otro lado se muestra mejor resultado sobre el método de watershed. Esto se debe a que el método de watershed es un método de segmentación poderoso, sin embargo, presenta una limitación clara, la imposición de mínimos. Esto genera que para escoger un número de clusters, deba imponerse un número específico de mínimos, sin acceder a la imagen, es decir, es necesario imponer los mínimos de manera automática. Esta imposición automática resulta en poco aproximadas segmentaciones. El método de watersheds presenta otras limitaciones, como la dependencia de un solo canal, por lo cual la segmentación debe realizarse por cada canal, ya que requiere de imágenes en niveles de gris. Adicionalmente no utiliza en ninguna forma la información espacial, ya que esta muestra una distribución sencilla, sin "cuencas". En cuanto a la segmentación jerárquica, la utilización de diferentes distancias no muestra una mejora en la segmentación, el resultado siempre fue un píxel separado y un cluster por el resto de los píxeles. Se requiere de más atención a este método.

Como se mencionó anteriormente este método ajusta los datos a funciones gaussianas, de manera que aproxima los datos a funciones de distribución. Lamentablemente este método asume una distribución normal para todos los datos, es decir, no toma en cuenta ninguna otra posible distribución que puedan tener los datos. Adicionalmente el método parece no converger para algunos casos de hsv, específicamente a un número de 4 o 5 cluster. En cuanto a los espacios de color, se encontró que los espacios más discriminativos son el espacio de color RGB y Lab, el HSV es un espacio que realmente no genera diferencias. En cuanto a estos dos espacios, los canales de RGB parecen contribuir por igual a la segmentación, ninguno es más discriminativo que el otro. En cuanto al espacio Lab, se muestra que el canal L, es más discriminativo que todos los demás, esto se puede notar en la forma resultante de los watersheds, en los cuales, el canal L, es aquel que presenta la mejor segmentación.

5. Discusión

5.1. Evaluación

Los problemas de segmentación pueden ser validados y comparados utilizando diversas métricas de evaluación, entre estas se encuentran las gráficas de desempeño (en función de un umbral), medida del traslape entre las regiones obtenidas y anotadas (índice de Jaccard), medidas basadas en la distancia normal entre los contornos tales como error medio cuadrático, distancia media absoluta, distancia máxima absoluta, entre otros. También se utilizan otras medidas de distancia tal como la distancia de Hausdorff. De igual forma, otros métodos de evalu-

ación corresponden a la definición de nuevos parámetros estadísticos, tales como la precisión y la sensibilidad, los cuales definen nuevas métricas de evaluación tales como el coeficiente DSC, X-square, curvas de precisión y sensibilidad, sensibilidad máxima, precisión máxima, sensibilidad y precisión medias, entre otros.[2][3] Ahora bien, cuando se tiene múltiples anotaciones de segmentación para una misma imagen, se puede proceder a realizar la siguiente metodología. Escogencia cualitativa de la mejor anotación entre el grupo de anotaciones o la formación de una nueva anotación resultante de la combinación de las anotaciones disponibles, generando una jerarquía de bordes, en la cual solo se van a mantener los bordes consistentes en la mayoría de las anotaciones.[3] Par escoger el grupo de anotaciones con las cuales se realizó la evaluación, se aplicó la metodología de selección cualitativa, en la cual el grupo de investigación decidió basado en un criterio subjetivo, cual de todas las anotaciones para cada imagen, debería escogerse para el desarrollo de la evaluación de los distintos métodos. La estrategia o métrica de evaluación que se escogió para validar y comparar los algoritmos presentados en el artículo, corresponde a una medida del traslape entre las regiones obtenidas con los distintos algoritmos y las anotaciones, es decir, se utilizó el índice de Jaccard para evaluar los métodos. Se implementó este método de evaluación debido al conocimiento pleno y a la familiaridad que se tiene de este método, además de la facilidad de implantación y análisis del mismo. No obstante, este método es contundente si se quiere analizar pocos objetos, en lo posible solo uno. Para los múltiples objetos es mejor utilizar una curva de sensibilidad y precisión. Ahora bien, se debe resaltar que en este proyecto se utilizó el índice de Jaccard debido a que la evaluación se realizó comparando el clúster más grande en la segmentación con el clúster más grande en las anotaciones.

6. Conclusiones

La combinación que presentó los mejores resultados de segmentación fue la atente al método de mezcla de gaussianas en el espacio de representación RGB. De igual forma, se debe resaltar que el método que presentó el menor rendimiento fue Watersheds debido a que este requiere que se haga una imposición correcta de mínimos locales, no obstante, el proceso de imposición de mínimos desarrollado en este estudio no fue el más adecuado, lo que conlleva a que este método no presentara buenos resultados. El color y la disposición espacial no son parámetros lo suficientemente fuertes para generar una excelente segmentación de una imagen por lo cual se recomienda adicionar nuevos parámetros tales como textura y forma, los cuales permitan darles robustez a los algoritmos de segmentación utilizados. Adicionalmente, se debe resaltar que el comportamiento de los métodos no es consistente a lo largo de todos los espacios

de representación. Lo que implica que la eficiencia de cada método va mejor si se utiliza en el espacio de representación adecuado. De igual forma, el número de clusters determina la cantidad de regiones que se van a segmentar en la imagen, por este motivo, se establece que, en un escenario ideal, el número de cluster que entra por parámetro debe ser igual o muy cercano al número de objetos en la imagen. Para realizar un análisis más contundente de los datos, se recomienda desarrollar una metodología de evaluación más certera. De igual forma, se resalta la importancia de utilizar las correctas anotaciones, para obtener mejores resultados.

References

- [1] Palomino, N. L. S., Concha, U. N. R. (2009). Técnicas de segmentación en Procesamiento digital de imágenes. Revista de investigación de Sistemas e Informática, 6(2), 9-16.
- [2] Métricas de evaluación para algoritmos de segmentación. (n.d.). Retrieved from <http://bibling.us.es/proyectos/fichero/PFC252FCapitulo V.pdf>
- [3] An optimal multiple threshold scheme for image segmentation - IEEE Xplore Document. (n.d.). Retrieved March 16, 2017, from <http://ieeexplore.ieee.org/document/6313341/>

7. Anexos



Figure 2. Imagen original de la iglesia



Figure 3. Anotacion de la imagen de la iglesia



Figure 4. Segmentacion para 3 clusters, con metodo de mezcla de gaussianas y en espacio de color lab



Figure 5. Segmentacion para 3 clusters, con metodo k means y en espacio de color lab



Figure 6. Segmentacion para 3 clusters, con metodo de watershed y en espacio de color lab



Figure 7. Imagen original del paisaje



Figure 10. Segmentacion para 4 clusters, con metodo mezcla de gaussianas y en espacio de color rgb



Figure 11. Segmentacion para 4 clusters, con metodo de watershed y en espacio de color rgb



Figure 8. Anotacion de la imagen de la iglesia




Figure 9. Segmentacion para 4 clusters, con metodo k means y en espacio de color rgb